


Tarea: EDA, clasificación de vinos y modularización

April 24, 2026

1. Enlace a tu repositorio de GitHub

https://github.com/josezavala6445-gif/MLOps_EDA_Hw

2. Captura de pantalla de la estructura del repositorio



```
MLOps_EDA_Hw/
├── README.md
├── requirements.txt
├── docs/
├── artifacts/
│   ├── eda/
│   └── wine_pipeline.joblib
├── src/
│   ├── datos.py
│   ├── metricas.py
│   ├── eda.py
│   ├── entrenamiento.py
│   └── prueba.py
└── ENTREGA.md
```

Checklist PDF y reporte de problemas

Salidas generadas al ejecutar (no en Git)

Gráficos del EDA

Descarga Kaggle + limpieza

Accuracy, precision, recall, F1

3. Captura de pantalla ejecutando eda.py

```

Successfully installed kagglehub-0.4.3
(.venv) (base) josemariazavala@Chemas-MacBook-Air MLOps_EDA_Hw % python src/eda.py

Warning: Looks like you're using an outdated `kagglehub` version (installed: 0.4.3), please consider upgrading to the latest version (1.0.0)
Fuente: kaggle:yasserh/wine-quality-dataset/WineQT.csv
Muestras: 1018, features: 11, clases: 6

--- Calidad de datos ---
Total celdas NaN en features: 0
Sin nulos. Duplicados eliminados en la carga (ver datos.py).

--- Estadísticas descriptivas (features) ---

```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates	alcohol
count	1018.000	1018.000	1018.000	1018.000	1018.000	1018.000	1018.000	1018.000	1018.000	1018.000	1018.000
mean	8.289	0.534	0.269	2.524	0.087	15.649	46.326	0.997	3.312	0.657	10.452
std	1.741	0.183	0.196	1.315	0.049	10.177	33.124	0.002	0.158	0.168	1.095
min	4.600	0.120	0.000	0.900	0.012	1.000	6.000	0.990	2.740	0.330	8.400
25%	7.100	0.390	0.090	1.900	0.070	7.000	21.000	0.996	3.210	0.550	9.500
50%	7.900	0.520	0.250	2.200	0.079	13.000	38.000	0.997	3.310	0.620	10.200
75%	9.100	0.645	0.420	2.600	0.090	21.000	62.000	0.998	3.400	0.720	11.200
max	15.900	1.580	1.000	15.500	0.611	68.000	289.000	1.004	4.010	2.000	14.900

```

--- Conteo por calidad (clase) ---
calidad 3: 6 muestras (0.6%)
calidad 4: 33 muestras (3.2%)
calidad 5: 433 muestras (42.5%)
calidad 6: 409 muestras (40.2%)
calidad 7: 122 muestras (12.0%)
calidad 8: 15 muestras (1.5%)

--- Etiquetas de clase ---
calidad_3
calidad_4
calidad_5
calidad_6
calidad_7
calidad_8
Guardado: /Users/josemariazavala/Downloads/ML and DS/MLOps_EDA_Hw/artifacts/eda/histogramas_clave.png
Guardado: /Users/josemariazavala/Downloads/ML and DS/MLOps_EDA_Hw/artifacts/eda/boxplots_por_clase.png
Guardado: /Users/josemariazavala/Downloads/ML and DS/MLOps_EDA_Hw/artifacts/eda/matriz_correlacion.png

--- Pares con mayor correlación positiva ---
fixed acidity vs density: 0.683
fixed acidity vs citric acid: 0.668
free sulfur dioxide vs total sulfur dioxide: 0.661

EDA terminado. Figuras en: /Users/josemariazavala/Downloads/ML and DS/MLOps_EDA_Hw/artifacts/eda

```

4. Captura de pantalla ejecutando entrenamiento.py

```

(.venv) (base) josemariazavala@Chemas-MacBook-Air MLOps_EDA_Hw % python src/entrenamiento.py

Warning: Looks like you're using an outdated `kagglehub` version (installed: 0.4.3), please consider upgrading to the latest version (1.0.0)
Fuente: kaggle:yasserh/wine-quality-dataset/WineQT.csv
Muestras: train=763, test=255, features=11, clases=6
/Users/josemariazavala/Downloads/ML and DS/MLOps_EDA_Hw/.venv/lib/python3.11/site-packages/sklearn/model_selection/_split.py:813: UserWarning: The least populated class in y has only 4 members, which is less than n_splits=5.
  warnings.warn(

CV F1 (weighted) - reg_logistica: media=0.5053, folds=[0.5305 0.6027 0.51 0.4675 0.4156]
/Users/josemariazavala/Downloads/ML and DS/MLOps_EDA_Hw/.venv/lib/python3.11/site-packages/sklearn/model_selection/_split.py:813: UserWarning: The least populated class in y has only 4 members, which is less than n_splits=5.
  warnings.warn(

CV F1 (weighted) - random_forest: media=0.5772, folds=[0.6298 0.6801 0.566 0.5039 0.5062]

Modelo elegido por CV (F1 weighted): random_forest

Métricas en entrenamiento (referencia)
accuracy: 0.8925
precision: 0.8979
recall: 0.8925
f1: 0.8927

Métricas en conjunto de prueba (modelo final)
accuracy: 0.5020
precision: 0.5089
recall: 0.5020
f1: 0.5037

Artefacto guardado en: /Users/josemariazavala/Downloads/ML and DS/MLOps_EDA_Hw/artifacts/wine_pipeline.joblib

```

5. Captura de pantalla ejecutando prueba.py

```
(.venv) (base) josemariazavala@Chemas-MacBook-Air M10ps_EDA_Hw % python src/prueba.py
Modelo cargado: random_forest
Datos: kaggle:yasserh/wine-quality-dataset/WineQT.csv

--- Métricas finales (conjunto de prueba) ---
accuracy: 0.5020
precision: 0.5089
recall: 0.5020
f1: 0.5037

--- Reporte por clase ---
precision    recall  f1-score   support

calidad_3    0.0000    0.0000    0.0000         2
calidad_4    0.0000    0.0000    0.0000         8
calidad_5    0.6373    0.6019    0.6190        108
calidad_6    0.4845    0.4608    0.4724        102
calidad_7    0.3721    0.5161    0.4324         31
calidad_8    0.0000    0.0000    0.0000         4

accuracy          0.5020        255
macro avg         0.2490    0.2631    0.2540        255
weighted avg      0.5089    0.5020    0.5037        255

Figura guardada en: /Users/josemariazavala/Downloads/ML and DS/M10ps_EDA_Hw/artifacts/matriz_confusion_test.png
(.venv) (base) josemariazavala@Chemas-MacBook-Air M10ps_EDA_Hw %
```

6. Reporte de problemas

Problema	¿Cómo lo resolviste?	¿Se resolvió?
Problema 1 — Métricas perfectas (1.0) con sklearn. Con <code>sklearn.datasets.load_wine</code> (178 muestras, 3 clases) los modelos alcanzaban <i>accuracy</i> y F1 de 1.0 en test, lo que no reflejaba un escenario realista ni permitía analizar errores ni sobreajuste.	Se cambió la fuente de datos a Kaggle (yasserh/wine-quality-dataset, archivo WineQT.csv) usando kagglehub en <code>datos.py</code> . El nuevo <i>dataset</i> tiene más filas, 6 niveles de calidad y clases desbalanceadas, lo que produce métricas más creíbles (~0.50–0.66 en test según la corrida).	Sí — dejaron de salir métricas de 1.0 en test y el informe puede discutir desempeño real y matriz de confusión con errores.
Problema 2 — Filas duplicadas en el CSV de Kaggle. El CSV de Kaggle contenía filas duplicadas (mismas <i>features</i> y misma <i>quality</i>); el EDA las detectaba (~125) pero al principio el entrenamiento podía usar datos distintos si la limpieza no era la misma en todos los módulos.	Se centralizó la limpieza en <code>cargar_vinos()</code> (<code>datos.py</code>): después de cargar el CSV se aplica <code>drop_duplicates()</code> sobre <i>features</i> + objetivo, de modo que <code>eda.py</code> , <code>entrenamiento.py</code> y <code>prueba.py</code> usan el mismo conjunto (~1018 muestras).	Sí — los conteos y modelos quedaron alineados en todo el <i>pipeline</i> .